



UNIVERSIDADE
Estadual de Londrina

GABRIEL JONAS AGUIAR

MELHORIA DE CONTRASTE EM IMAGENS DIGITAIS
BASEADA EM INTELIGÊNCIA ARTIFICIAL

LONDRINA-PR

2017

GABRIEL JONAS AGUIAR

**MELHORIA DE CONTRASTE EM IMAGENS DIGITAIS
BASEADA EM INTELIGÊNCIA ARTIFICIAL**

Trabalho de Conclusão de Curso apresentado
ao curso de Bacharelado em Ciência da Com-
putação da Universidade Estadual de Lon-
drina para obtenção do título de Bacharel em
Ciência da Computação.

Orientador: Prof. Dr. Bruno Bogaz Zarpelão
Coorientador: Prof. Dr. Sylvio Barbon Ju-
nior

LONDRINA-PR

2017

Gabriel Jonas Aguiar

Melhoria de Contraste em Imagens Digitais baseada em Inteligência Artificial/
Gabriel Jonas Aguiar. – Londrina-PR, 2017-
65 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Bruno Bogaz Zarpelão

– Universidade Estadual de Londrina, 2017.

1. Processamento de Imagem. 2. Visão Computacional. 3. Aprendizado de
Máquina. 4. Melhoria de Contraste. I. Prof. Dr. Bruno Bogaz Zarpelão. II.
Universidade Estadual de Londrina. III. Curso de Ciência da Computação. IV.
Melhoria de Contraste em Imagens Digitais baseado em Inteligência Artificial

CDU 02:141:005.7

GABRIEL JONAS AGUIAR

**MELHORIA DE CONTRASTE EM IMAGENS DIGITAIS
BASEADA EM INTELIGÊNCIA ARTIFICIAL**

Trabalho de Conclusão de Curso apresentado
ao curso de Bacharelado em Ciência da Com-
putação da Universidade Estadual de Lon-
drina para obtenção do título de Bacharel em
Ciência da Computação.

BANCA EXAMINADORA

Prof. Dr. Bruno Bogaz Zarpelão
Universidade Estadual de Londrina
Orientador

Prof. Dr. Alan Salvany Felinto
Universidade/Instituição do Segundo
Membro da Banca

Prof. Ms. Luiz Fernando Carvalho
Universidade/Instituição do Terceiro
Membro da Banca

Londrina-PR, 24 de novembro de 2017

AGRADECIMENTOS

Agradeço primeiramente a Deus que me capacitou e realizou Sua vontade em minha vida. Também sou grato aos meus pais, Valdeci e Elda que me deram todo apoio em minha vida pessoal e acadêmica, ao meu irmão Vinicius que mesmo em outra país sempre demonstrou apoio, e a todos meus familiares.

Também agradeço aos professores e funcionários da Universidade que promoveram um ambiente de aprendizado e me ajudaram a chegar até aqui. Em especial, agradeço ao Prof. Dr. Sylvio Barbon Jr. por me orientar durante a Iniciação Científica, e co-orientar este trabalho, e ao Prof. Dr. Bruno Bogaz Zarpelão por me orientar durante este trabalho.

E finalmente, agradeço a todos meus amigos de turma que ajudaram toda essa caminhada ser mais leve e mais alegre, e aos meus amigos Rafael Leite, Nicolas Kloc, Guilherme Rocha, Felipe Balthazar, Igor Vieira, Victor Cestari e Jaqueline Telles, por muitas vezes me ouvir e me ajudar continuar firme nos meus objetivos.

*"Meus irmãos, considerem motivo de grande alegria o fato de passarem por diversas
provações pois vocês sabem que a prova da sua fé produz perseverança. E a perseverança
deve ter ação completa, a fim de que vocês sejam maduros e íntegros, sem lhes faltar
coisa alguma"*

(Bíblia Sagrada, Tiago 1, 2-4)

AGUIAR, G. J.. **Melhoria de Contraste em Imagens Digitais baseada em Inteligência Artificial**. 65 p. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual de Londrina, Londrina-PR, 2017.

RESUMO

A melhoria de contraste em imagens é muito importante no campo da Visão Computacional. Muitas das abordagens para melhoria de contraste estão ligadas a operações no histograma, operações globais ou locais. O *Contrast Limited Adaptative Histogram Equalization* (CLAHE) utiliza equalização local na imagem, porém é necessário a escolha de dois parâmetros: *Number of tiles* e *Clip Limit*. A escolha de um parâmetro ruim faz com que o algoritmo não tenha um bom resultado. Portanto, considerando a falta de métodos para determinar esses parâmetros de forma eficiente, esse trabalho apresenta uma abordagem utilizando aprendizado de máquina para fazer a seleção de parâmetros para o CLAHE. O método proposto foi construído e avaliado utilizando distorções de contraste de bases conhecidas de IQA. Também foi criada uma base com distorções variadas de contraste e intensidade com mais de 6200 imagens. Os resultados mostraram a eficiência do método proposto em prever os parâmetros do CLAHE com 0,014 de RMSE e 0,935 R^2 . Nosso método também é melhor que as *baselines* experimentadas, e aumenta o contraste enquanto mantém o aspecto natural.

Palavras-chave: Processamento de Imagem. Visão Computacional. Aprendizado de máquina. Melhoria de Contraste.

AGUIAR, G. J.. **Contrast Enhancement in Digital Images based on Artificial Intelligence**. 65 p. Final Project (Bachelor of Science in Computer Science) – State University of Londrina, Londrina–PR, 2017.

ABSTRACT

Contrast enhancement plays a major role in Computer Vision field. Most of the contrast enhancement techniques are based on histogram modifications, which can be performed globally or locally. The Contrast Limited Adaptive Histogram Equalization is a method which can overcome the limitations of global approaches by performing local contrast enhancement. However, this method relies on two essential hyperparameters: the *Number of Tiles* and the *Clip Limit*. An improper hyperparameter selection may heavily decrease the image quality toward its degradation. Considering the lack of methods to efficiently determine these hyperparameters, this article presents a learning-based hyperparameter selection method for the Contrast Limited Adaptive Histogram Equalization technique. The proposed supervised method was built and evaluated using contrast distortions from well-known Image Quality Assessment datasets. Also, we introduce a more challenging dataset containing over 6200 images with a large range of contrast and intensity variations. The results show the efficiency of the proposed approach in predicting clahe hyperparameters with up to 0.014 RMSE and 0.935 R^2 values. Also, our method overcomes both experimented baselines by enhancing image contrast while keeping its natural aspect.

Keywords: Contrast Enhancement. Computer Vision. Machine Learning. Image Processing.

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de árvore de decisão para classificação	27
Figura 2 – Exemplo de árvore de decisão para regressão	27
Figura 3 – Exemplo de neurônio. Traduzido de [1]	28
Figura 4 – Exemplo de rede neural. Traduzido de [2]	29
Figura 5 – Exemplo de funcionamento do <i>Gradient Boosting</i> . Traduzido de [3] . . .	30
Figura 6 – Exemplo de modelo de classificação SVM. Traduzido de [4]	31
Figura 7 – Exemplificação da Random Forest. Traduzido de [5]	32
Figura 8 – Histogramas com e sem equalização	36
Figura 9 – Aplicação dos métodos em uma imagem real de uma ressonância mag- nética de um joelho [6]	38
Figura 10 – Variação de parâmetros do CLAHE. Imagem original (a) , Imagem dis- torcida (b) , CLAHE com parâmetros ruins: $CL = 0,01$ e $NT = [8, 8]$ (c) , CLAHE com parâmetros ideais: $CL = 0,025$ e $NT = [4, 4]$ (d) , CLAHE com parâmetros não adequados: $CL = 0,468$ e $NT = [16, 16]$ (e)	39
Figura 11 – Visualização do processo nos histogramas	42
Figura 12 – Distorções de contraste no Dataset 2 . Imagem Original (a) , Com- pressão de -50% (b) , Compressão de 10% (c) , Compressão de 30% (d) , Compressão de 50% (e) , Compressão de 70% (f) , Compressão de 90% (g)	43
Figura 13 – Deslocamento no histograma do Dataset 2 . Imagem com contraste distorcido com 90% de compressão (a) , 10 bins para direita (b) , 30 para direita (c) , 60 para direita (d) , 10 bins para esquerda (e) , 30 para esquerda (f) , 60 bins para esquerda (g)	44
Figura 14 – Comparação visual entre o método proposto em [7] e LB-CLAHE. Ima- gem Escritório (a) , Imagem área (b) , Imagem do anúncio (c)	51
Figura 15 – Importância de cada um dos descritores extraídos dos modelos da <i>Ran- dom Forest</i> , para ambos <i>datasets</i> e parâmetros.	52
Figura 16 – Performance do LB-CLAHE e as outras técnicas escolhidas utilizando IQA	53
Figura 17 – Os melhores resultados do LB-CLAHE de acordo com as técnicas de IQA em diferentes cenários. Grande diminuição do contraste (A) , di- minuição mediana do contraste (B) , diminuição leve do contraste (C) , aumento de contraste (D) . Imagem ideal (1) , imagem distorcida (2) , equalização de histograma global (3) , CLAHE com valores fixos (4) , valor proposto pelo LB-CLAHE (5)	54

Figura 18 – Os piores resultados do LB-CLAHE de acordo com as técnicas de IQA. Os melhores resultados da equalização de histograma global **(A)** e **(B)**, melhores resultados do CLAHE com parâmetros fixos **(C)** e **(D)**. Imagem ideal **(1)**, imagem distorcida **(2)**, equalização global do histograma **(3)**, valores fixos do CLAHE **4**, valor proposto pelo LB-CLAHE **(5)** . 55

LISTA DE TABELAS

Tabela 1	–	Lista de todos os descritores extraídos.	46
Tabela 2	–	Configuração dos Experimentos	47
Tabela 3	–	Performance dos algoritmos de AM no Dataset 1	49
Tabela 4	–	Performance dos algoritmos de AM no Dataset 2	49
Tabela 5	–	Valores médios de similaridade para o Dataset 1 e Dataset 2.	54

LISTA DE ABREVIATURAS E SIGLAS

SVM	<i>Support Machine Vector</i>
RF	<i>Random Forest</i>
MLP	<i>Multilayer Perceptron</i>
NT	<i>Number of Tiles</i>
CL	<i>Clip Limit</i>
IQA	<i>Image Quality Assesment</i>
AM	Aprendizado de Máquina

SUMÁRIO

1	INTRODUÇÃO	21
2	FUNDAMENTAÇÃO TEÓRICA	25
2.1	Aprendizado de máquina	25
2.1.1	Árvores de classificação e regressão	26
2.1.2	<i>Multilayer Perceptron</i>	28
2.1.3	XGBoost	29
2.1.4	Máquina de vetores de suporte	30
2.1.5	<i>Random Forest</i>	31
2.2	Processamento Digital de Imagem	31
2.2.1	<i>Image Quality Assessment</i>	32
2.2.1.1	<i>Mean Squared Error</i>	32
2.2.1.2	<i>Peak Signal-to-Noise Ratio</i>	33
2.2.1.3	<i>Structural Similarity</i>	33
2.2.1.4	<i>Gray Level Entropy Difference</i>	33
2.2.1.5	<i>Statistical Naturalness Measure</i>	34
2.2.1.6	<i>Measure of Enhancement</i>	34
2.2.1.7	<i>Global Contrast Factor</i>	34
2.2.2	<i>Local Binary Patterns</i>	35
2.2.3	Matriz de coocorrência	35
2.2.4	Melhoria de contraste em imagens digitais	35
2.2.4.1	Histograma	35
2.2.4.2	Equalização de Histograma	36
2.2.4.3	<i>Contrast Limited Adaptive Histogram Equalization</i>	36
3	DESENVOLVIMENTO	41
3.1	Materiais e Métodos	41
3.1.1	Construção das bases	41
3.1.2	Rotulação do Dataset	43
3.1.3	Descritores de Imagem	45
3.1.4	Algoritmos utilizados	45
3.1.5	Medidas de Avaliação	46
4	RESULTADOS	49
4.1	Performance Preditiva	49
4.2	Comparação visual	50

4.3	Importância dos descritores	50
4.4	Avaliação com IQA	52
5	CONCLUSÃO	57
	REFERÊNCIAS	59

1 INTRODUÇÃO

A melhoria de imagens digitais consiste em melhorar a qualidade da imagem, permitindo uma visualização melhor e uma melhor análise computacional [8]. Esse processo é usado em diversas aplicações por permitir que alguns problemas nos sistemas de aquisições das imagens sejam superados [9, 10]. Alguns exemplos de processos de melhoria de imagens digitais são remoção de ruído e melhoria de contraste.

O conceito da melhoria de contraste consiste em aumentar a variedade de níveis de cinza em uma imagem que está sendo processada [11]. Esse tipo de processamento exerce um papel muito importante nas áreas de processamento de imagem digital, visão computacional e reconhecimento de padrão [12, 13].

Além de melhorar a visualização da imagem por melhorar a aparência da imagem, a melhoria de contraste também pode ser usada para melhorar a performance de tarefas sucessivas, como análise da imagem, detecção de objetos e segmentação de imagens [10, 13, 14]. Esse tipo de processamento tem contribuído para diversos campos como análise de imagens médicas, televisão em alta definição, imagens de raio-X industrial, imagens microscópicas e sensores remotos [15].

A maioria das técnicas de melhoria de contraste são baseadas em ajustes no histograma, devido a facilidade de implementação [14]. Uma revisão das técnicas baseadas em histograma podem ser encontradas em [15]. Essas técnicas podem ser separadas em dois grupos: técnicas locais ou globais. O uso da melhoria de contraste global pode não ter sucesso em imagens em que ajustes em detalhes locais são necessários ou em imagens que tem uma grande variação de iluminação, mas se esse processo é feito utilizando técnicas locais é possível superar essas limitações [16, 17, 13].

O *Contrast Limited Adaptive Histogram Equalization* (CLAHE) [6] é um método popular para melhoria de contraste local. Ele se mostra poderoso e útil em diversas aplicações [18, 19, 13].

O CLAHE tem sido muito utilizado para melhoria de contraste em diversas aplicações de visão computacional e reconhecimento de padrão. Na área médica, tem sido aplicado em ultrassom de mamas e melhoria de imagens de mamografia [20, 21, 22], em segmentação de imagens de células [23, 24], em processamento de imagens de vasos da retina [25, 26, 27], e para realçar imagens de fraturas ósseas [28]. Além da área médica, o CLAHE foi utilizado para realçar imagens embaixo d'água [29, 30, 31], para segmentar frutas em sistemas agrícolas [32, 33, 34], em sistemas de assistência de direção para melhorar a detecção de veículos [35], para detecção de sinais [36] e para detecção de pedestres [37].

A principal desvantagem do CLAHE, vista em [7, 38], é a dificuldade em fazer a escolha dos parâmetros, o *Clip Limit* (CL) e o *Number of Tiles* (NT), adequados visto que uma escolha ruim de parâmetros leva a perda de qualidade da imagem. Muitos trabalhos utilizam parâmetros fixos escolhidos empiricamente para resolver um problema específico [39, 32, 40, 41]. Um método baseado na entropia da imagem para automaticamente selecionar os parâmetros do CLAHE foi proposto em [7]. Ele se utiliza das características de duas curvas de entropia (CL pela entropia e NT pela entropia). O objetivo é determinar os valores de CL e do NT no ponto com a maior curvatura de cada curva da entropia. Para encontrar essas funções, é necessário calcular a entropia para cada saída do CLAHE para cada possibilidade de combinação entre CL e NT. Contudo, apesar dos resultados mostrarem que a proposta é capaz de melhorar o contraste da imagem com pouca deterioração, o processo é computacionalmente impraticável. Avaliar todas as possíveis combinações entre CL e NT para o cálculo da entropia é uma tarefa com um custo computacional muito elevado.

Um *tuning* de parâmetros para o CLAHE baseado em uma meta-heurística multi-objetiva foi proposto em [42]. Além da entropia, como proposto em [7], os autores utilizaram o *Structural Similarity Index* (SSIM) para encontrar os parâmetros do CLAHE. Uma vez que o SSIM está relacionado a distorção da imagem, o objetivo é maximizar o ganho de informação pela entropia ao mesmo tempo que minimiza a distorção via SSIM. Apesar das duas funções serem contrárias, o uso de diferentes níveis de contraste fez com que fosse possível realçar diferentes estruturas presentes nas imagens.

Durante essa pesquisa, além de [7], nenhum outro método automático para determinar os parâmetros do CLAHE dada uma imagem foi encontrado. Considerando a falta de soluções para esse problema, especialmente uma solução rápida, nesse trabalho propomos uma técnica baseada em aprendizado de máquina supervisionado para seleção desses parâmetros. Uma das principais razões pela qual o aprendizado de máquina supervisionado foi selecionado para resolver esse problema é que apesar do treinamento de um modelo de regressão ou classificação ser uma tarefa computacionalmente complexa, a predição é relativamente rápida. Além disso, métodos de aprendizado de máquina supervisionado têm se mostrado poderosos na resolução de problemas relacionados a imagem [43, 44, 45, 46, 47]. Assim, propomos um modelo supervisionado, capaz de determinar automaticamente os parâmetros do CLAHE para imagens de diferentes distorções de contraste.

Este trabalho propõe uma solução para o problema de parametrização do CLAHE utilizando Aprendizado de Máquina. Nosso método, denominado LB-CLAHE (*Learning Based-CLAHE*), a partir de uma base de imagens rotuladas com parâmetros ideais, e juntamente com os descritores extraídos de uma imagem aplicado em modelos induzidos por algoritmos de AM, sugere os parâmetros ideais. Para a avaliação de nossa proposta,

utilizamos métricas tradicionais no campo de AM para a avaliação da predição e métricas de IQA (*Image Quality Assessment*) para avaliação das imagens resultantes.

No Capítulo 2, é apresentado a fundamentação teórica do trabalho, dividida em Aprendizado de Máquina e os algoritmos utilizados, e Processamento de Imagens Digitais, apresentando as métricas e processos utilizados. No Capítulo 3, são apresentados os materiais e métodos utilizados, divididos em cinco subseções: na Seção 3.1.1, a construção das bases, na Seção 3.1.2, a rotulação das bases, na Seção 3.1.3, os descritores utilizados, na Seção 3.1.4, é apresentado os algoritmos utilizados e por fim na Seção 3.1.5, as métricas utilizadas para avaliar os algoritmos da seção anterior. No Capítulo 4, são apresentados os resultados obtidos e uma discussão sobre eles. Finalmente, no Capítulo 5, temos a conclusão deste trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

Para um melhor entendimento deste trabalho, será apresentado a fundamentação teórica sobre os conceitos e processos utilizados para a realização do mesmo. Primeiramente, serão apresentados os conceitos relacionados ao Aprendizado de Máquina, e os algoritmos utilizados nesse trabalho. Em seguida serão apresentados os conceitos relacionados ao Processamento de Imagem Digital, sendo eles separados entre métricas de avaliação, descritores de textura e melhoria de contraste em imagens digitais.

2.1 Aprendizado de máquina

O Aprendizado de Máquina [48] é uma área de estudo da Inteligência Artificial, que contém uma variedade de algoritmos que têm como meta gerar uma função, ou até um conjunto de funções, que dados alguns descritores ou características (que descrevem o problema) seja capaz de elaborar modelos que possam aprender conforme a experiência.

A experiência necessária podem ser tuplas em um banco de dados, em que cada valor descreve uma característica daquela instância, podendo ter um valor real, classificatório ou binário. Existem duas abordagens de aprendizado de máquina, supervisionado e não supervisionado. Caso as amostras fornecidas para o treinamento do modelo já possuírem os valores de saída corretos, o aprendizado é dito como supervisionado, do contrário é chamado de aprendizado não supervisionado.

Em relação aos problemas a serem resolvidos por Aprendizado de Máquina supervisionado, existem dois tipos, classificação e regressão [49]. Problemas de regressão são problemas em que um valor real deve ser predito para amostras desconhecidas. Esse tipo de problema pode ser exemplificado, em previsões de pontuações em jogos de *Fantasy*, em que existem alguns descritores de desempenho de cada jogador, como número de jogos, número de gols, pontuação do adversário e o algoritmo de Aprendizado de Máquina buscaria determinar um valor provável para o atributo alvo a partir dos atributos, nesse caso a pontuação final do jogador. Em problemas de classificação, busca-se separar os dados em grupos finitos e discretos, como utilizar dados de e-mails para filtrá-los entre *spam* e não-*spam* [50]. Nesse trabalho o problema é classificado como um problema de regressão, visto que os valores dos parâmetros são valores contínuos reais.

Para elaborar o modelo computacional, é necessário que o algoritmo de Aprendizado de Máquina passe pela etapa de treinamento, em que através do ajuste de funções busca-se reduzir o erro, que seria a diferença entre a saída esperada e a saída dada pelo algoritmo. Em algoritmos não supervisionados, são utilizadas métricas para medir a similaridade entre as amostras, buscando agrupar as mais semelhantes. Nos algoritmos

supervisionados utiliza-se a diferença entre a saída estimada e o valor real daquela amostra.

Neste trabalho foram utilizados os seguintes algoritmos de aprendizado de máquina *Classification and Regression Tree* (CART) [51], *Multi-layer Perceptron* (MLP) *Artificial Neural Network* [52], *Support Vector Machine* (SVM) [53], *Random Forest* (RF) [54], e *Extreme Gradient Boosting* (XGBoost) [55].

2.1.1 Árvores de classificação e regressão

Árvores de classificação e regressão (*Classification and Regression Tree* (CART)) [51] é um algoritmo de aprendizado de máquina para criar árvores de decisão através da partição dos dados e da aplicação de um modelo de predição em cada partição.

Uma árvore de decisão é organizada no formato de árvore em que cada nó representa um atributo do conjunto de dados. Cada nó dessa árvore reparte o conjunto de dados em conjuntos cada vez menores com uma menor desordenação. O processo de divisão é feito até que todos os dados em um nó pertençam a uma mesma classe ou algum critério de parada seja atingido.

Árvores de classificação são utilizadas para problemas que contém um número finito de valores desordenados, com o erro sendo medido através da contabilização de classificações erradas.

Árvores de regressão são usadas para variáveis que assumem valores contínuos com o erro sendo medido pela diferença entre o valor estimado e o valor real. O CART utiliza uma generalização da variância binomial chamada coeficiente de Gini [51], para avaliar o quão puro estão os dados, isto é, são classificados da mesma forma.

Nas Figuras 1 e 2, temos o uso dos dois tipos de árvores, classificação e regressão utilizando a base de dados Iris [56]. No caso da classificação, busca-se através de atributos da planta determinar sua espécie. Em cada nó da árvore pode ser visto a classe mais frequente nos subconjuntos em que a árvore os separou, e tendo os nós folha com as predições. Na regressão o objetivo é predizer o tamanho da pétala da planta, utilizando os atributos fornecidos.

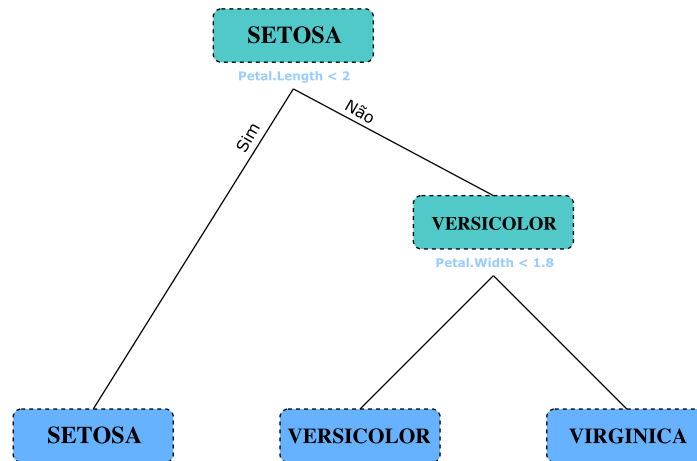


Figura 1 – Exemplo de árvore de decisão para classificação

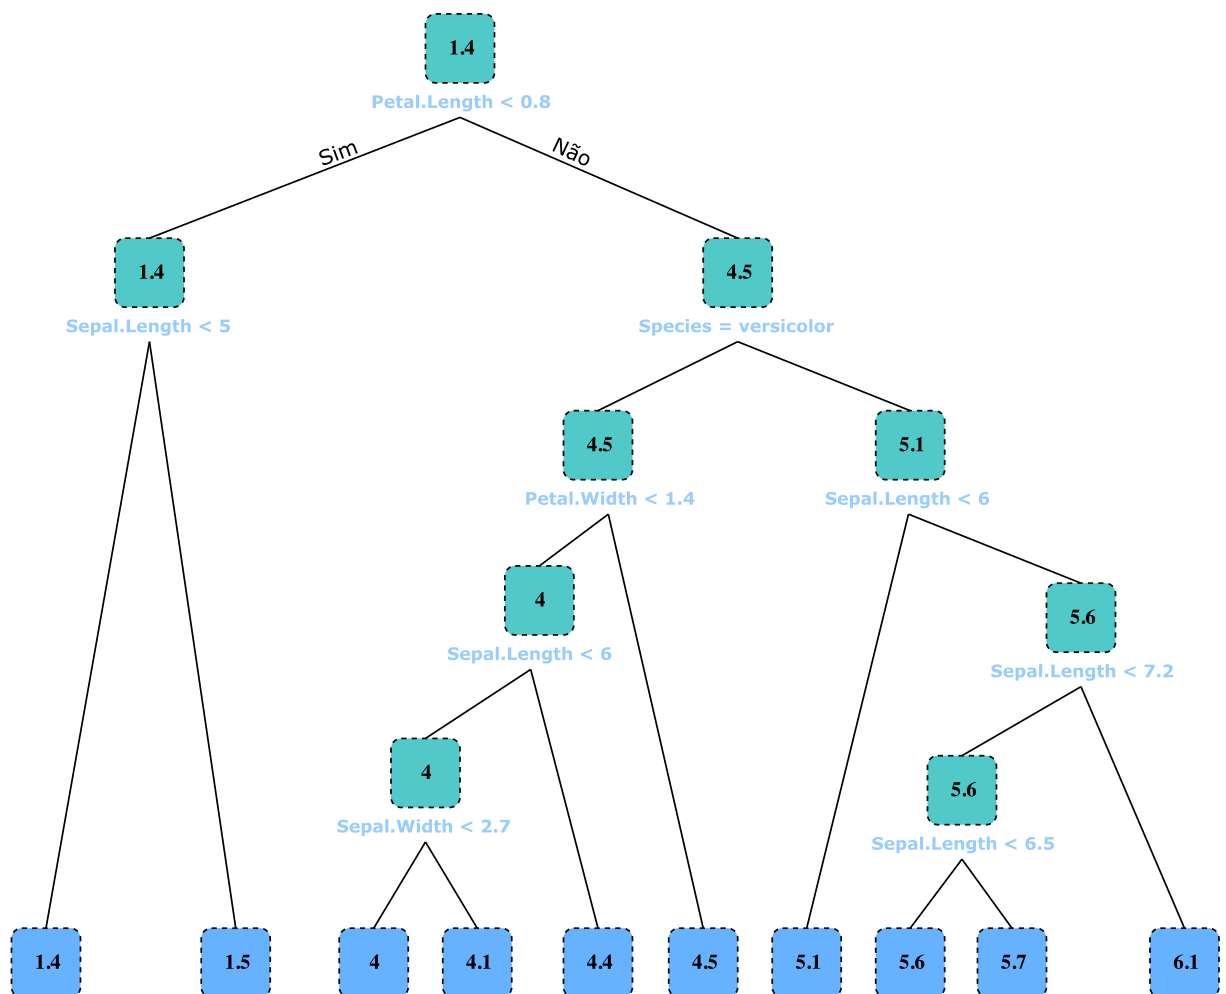


Figura 2 – Exemplo de árvore de decisão para regressão

2.1.2 Multilayer Perceptron

Multilayer Perceptron (MLP) é uma importante classe das redes neurais [52], capaz de lidar com problemas de classificação e regressão.

Ela é composta de vários nós chamados neurônios, organizados em camadas. Cada unidade simula a estrutura de um neurônio biológico fazendo um processamento sobre o sinal de entrada e gerando um sinal de saída. Cada neurônio faz 2 processamentos, o primeiro é a soma dos pesos multiplicados pelos valores de entrada do neurônio, após essa soma e antes da informação ser passada para a camada seguinte, é aplicado sobre o valor da soma uma função chamada função de ativação, que pode variar de acordo com a implementação. Um exemplo de neurônio pode ser visto na Figura 3, em que x_1, \dots, x_m são as entradas, w_{k1}, \dots, w_{km} são os pesos aos quais as entradas serão multiplicadas, e posteriormente somados, junto ao Bias, que é um valor adicionado a soma da entrada multiplicada pelos pesos, que são utilizados para ajudar a modelar os dados, e então passado para função de ativação ($\phi()$) e resulta na saída y_k .




Figura 3 – Exemplo de neurônio. Traduzido de [1]

Os pesos pelos quais a entrada de cada neurônio será multiplicada é o que precisa ser treinado em uma rede neural para atingir um melhor desempenho. Para fazer esse treinamento pode-se aplicar o algoritmo de *back-propagation* [52], em que se utiliza a saída e o erro entre a saída da MLP e a saída esperada para ajustar os pesos fazendo o caminho inverso.

Comumente, os neurônios de uma rede são organizados em três componentes, a camada de entrada, uma ou mais camadas invisíveis e a camada de saída. Um exemplo de organização de uma MLP pode ser visto na Figura 4. A primeira camada recebe os valores de entrada, que são processados pelas camadas invisíveis, gerando uma saída para a camada de saída.

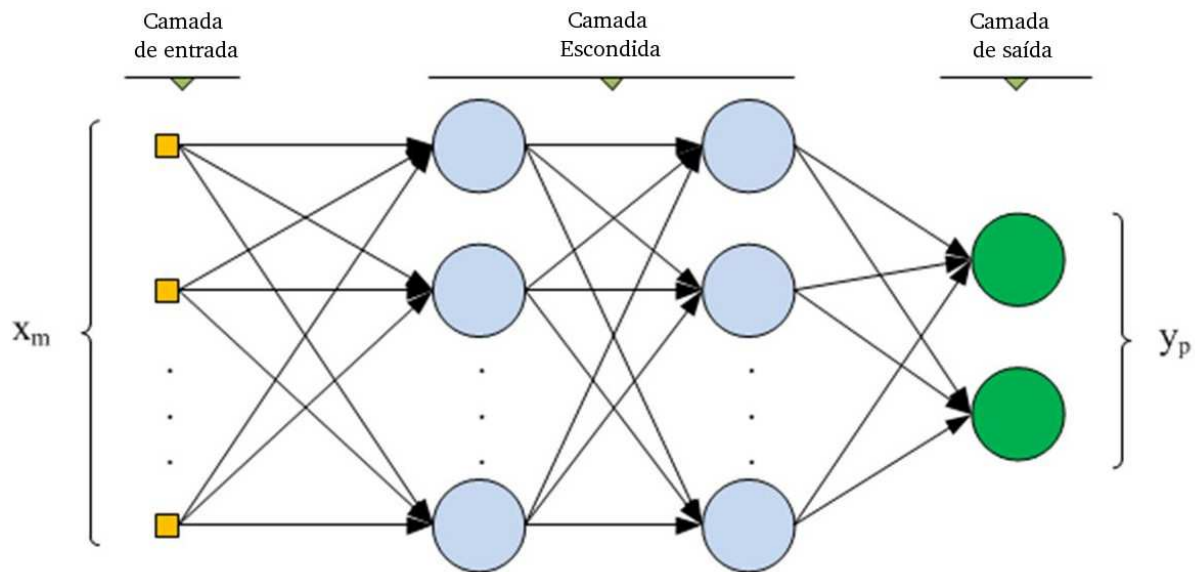


Figura 4 – Exemplo de rede neural. Traduzido de [2]

2.1.3 XGBoost

O *Gradient Boosting* tem como ideia utilizar um algoritmo de aprendizado fraco e melhorá-lo gradativamente para conseguir uma boa performance preditiva, podendo ser utilizado com vários algoritmos. Para atingir esses objetivos, ele se utiliza de uma técnica chamada *Boosting* para fazer o treinamento de cada um dos preditores. Primeiramente, é definida uma função, chamada função de perda, que irá fazer os cálculos para verificar o ruído de cada preditor, isto é, o quanto aquele preditor errou para uma dada instância. Então, para cada novo preditor treinado, o objetivo dele é prever o ruído do preditor anterior, para que ao final, a soma de todos os preditores chegue ao valor o qual a instância foi rotulada.

Na Figura 5 pode ser visto um exemplo do *Gradient Boosting*. No quadro de referência temos como deveria ser a curva de predição, e em sequência o resultado de três árvores fazendo a predição do ruído resultante da árvore anterior.




Figura 5 – Exemplo de funcionamento do *Gradient Boosting*. Traduzido de [3]

O XGBoost [55] é um sistema baseado no Gradient Boosting Machine (GBM) framework, que é o estado da arte em vários problemas. Ele utiliza paralelismo em várias partes da execução do algoritmo e normalizações nos dados para conseguir uma performance cada vez mais rápida.

2.1.4 Máquina de vetores de suporte

A Máquina de vetores de suporte (*Support Vector Machine* (SVM)) [53] é um algoritmo baseado em núcleo (*kernel-based*) de classificação e regressão. Ela tem sido utilizada para resolver diversos problemas de vários tipos, apresentando uma grande acurácia e capacidade de lidar com dados de alta dimensionalidade [57, 58]. Também apresenta ótimos resultados em problemas de classificação binária como filtragem de e-mails entre *spam* e não-*spam* [50].

Para a elaboração do modelo, ela busca um hiperplano que separe as classes de forma ótima, aumentando a fronteira para decisão entre as classes, ou minimizando a função de perda em problemas de regressão. Os pontos na fronteiras que são utilizados para a margem de decisão, são os vetores de suporte. Como a SVM é um algoritmo baseado em núcleo, portanto podemos utilizar diferentes núcleos de acordo com o problema. Na Figura 6, está sendo utilizando um núcleo linear, mas pode-se utilizar também funções de base radial.




Figura 6 – Exemplo de modelo de classificação SVM. Traduzido de [4]

2.1.5 *Random Forest*

O algoritmo de *Random Forest* (RF) é um algoritmo de AM baseado em *Ensembles*. Um *Ensemble* é uma junção de vários preditores, potencialmente fracos, que utiliza a junção de suas predições para chegar a resposta final, que aumenta a generalidade do preditor. Para fazer o treinamento de cada preditor é utilizado um subconjunto de dados. Para fazer essa divisão dos dados existem algumas técnicas. O *Boosting* que é utilizado pelo XGBoost 2.1.3 é baseado nos erros de cada preditor. A *Random Forest* utiliza a técnica de *Bagging* que usa uma amostragem aleatória do conjunto total de dados com reposição.

A RF gera várias árvores de decisão utilizando como treinamento os diferentes subconjuntos de dados. Cada árvore também utiliza atributos escolhidos aleatoriamente. Esse tipo de procedimento permite que uma variação grande dos dados seja explorada. A definição de como cada árvore da RF funciona está na seção 2.1.1. Na Figura 7 pode-se observar como os dados caminham durante a execução do algoritmo.

Para problemas de classificação, a saída da RF é definida pelo voto da maioria, em problemas de regressão a média entre todas as árvores é utilizada [59].

2.2 Processamento Digital de Imagem

Imagens digitais em um sistema computacional são representadas por uma matriz em que cada posição específica da matriz contém informações sobre cor, que são chamados de pixels [11]. Com essas informações é possível aplicar operações de diversas formas e objetivos diferentes, como aumento de contraste, identificação de objetos, pessoas, entre outras.

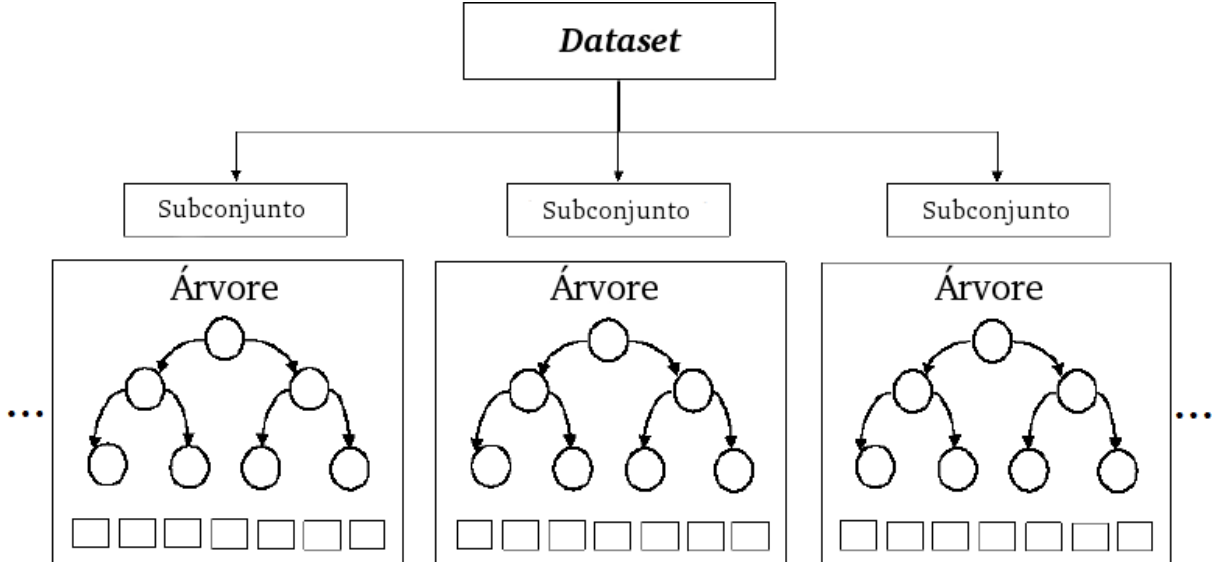


Figura 7 – Exemplificação da Random Forest. Traduzido de [5]

2.2.1 Image Quality Assessment

O campo de *Image Quality Assessment* (IQA) busca desenvolver métricas para avaliação de qualidade em imagens digitais que sejam consistentes com as avaliações subjetivas de humanos. As avaliações de humanos especialistas que possuem bons resultados, porém são muito caras e lentas para problemas reais [60]. Os métodos de IQA podem ser divididos em três grupos: *full-reference* (FR), *no-reference* (NR), *reduced-reference* (RR). Os algoritmos FR fazem uma comparação entre uma imagem ideal, que é assumido que tenha a qualidade perfeita, e a distorcida. Técnicas NR são utilizadas quando não temos a imagem de referência, e as RR quando apenas alguma informação parcial sobre a imagem de referência está disponível. A maioria das métricas de IQA são baseadas na estimativa da qualidade de ruídos, compressão e erros de transmissão [61].

2.2.1.1 Mean Squared Error

O *Mean Squared Error* (MSE) é uma métrica de IQA do grupo *full-reference*, isto é, é necessário uma imagem de referência. É utilizada para medir as diferenças entre as imagens. A Equação 2.1 mostra como é calculada a métrica, em que $I(x, y)$, com resolução $M * N$, é a imagem referência, e $ID(x, y)$ a imagem distorcida.

$$MSE = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} [I(x, y) - ID(x, y)]^2 \quad (2.1)$$

2.2.1.2 *Peak Signal-to-Noise Ratio*

Peak Signal-to-Noise Ratio (PSNR) é a razão entre a energia máxima de um sinal e o ruído que afeta a fidelidade da sua representação. Ele é uma métrica de IQA *full-reference*, calculada como na Equação 2.2, onde B é o número de *bits* por pixel da imagem.

$$PSNR = 10 \log\left(\frac{2^B - 1^2}{MSE}\right) \quad (2.2)$$

2.2.1.3 *Structural Similarity*

O algoritmo de *Structural Similarity* (SSIM) [62] foi desenvolvido para aprimorar o MSE e o PSNR, portanto uma métrica *full-reference*, e é utilizado para medir a similaridade entre duas imagens. Enquanto o MSE e PSNR utilizam erros absolutos, o SSIM considera o impacto de três características de uma imagem: luminância, contraste e estrutura. O índice é calculado utilizando esses três termos como mostra a Equação 2.3, considerando x e y como duas imagens, uma como referência e outra como distorcida, e α, β e γ pesos a serem definidos. O cálculo de cada um dos termos, é feito de acordo com as Equações 2.4, 2.5 e 2.6, sendo $\mu_x, \mu_y, \sigma_x, \sigma_y$ e σ_{xy} , o valor médio da imagem, o desvio padrão e a covariância cruzada das imagens x,y, respectivamente e C_1, C_2 e C_3 constantes.

$$SSIM(x, y) = [l(x, y)]^\alpha [c(x, y)]^\beta [s(x, y)]^\gamma \quad (2.3)$$

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1} \quad (2.4)$$

$$c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \quad (2.5)$$

$$s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3} \quad (2.6)$$

2.2.1.4 *Gray Level Entropy Difference*

A entropia (uma medida estatística de aleatoriedade) de uma imagem em níveis de cinza está relacionada ao seu contraste [7, 61, 63]. Assim então, a diferença da entropia entre a imagem original e a corrigida pelo CLAHE pode ser útil para identificar as imagens com contraste similar [63]. Essa métrica é chamada *Gray Level Entropy Difference* (GLED). A entropia é calculada como mostra a Equação 2.7, onde p é o histograma normalizado e N é número de tons de cinza na imagem, usualmente 256.

$$- \sum_i^N p_i * \log_2(p_i) \quad (2.7)$$

2.2.1.5 *Statistical Naturalness Measure*

Statistical Naturalness é uma medida subjetiva que é difícil de definir quantitativamente. O contraste e o brilho de uma imagem digital são os atributos que possuem maior correlação com a naturalidade da imagem [64]. Esses foram os atributos pelos quais [64] se baseou para criar o modelo de *Statistical Naturalness*. O modelo está descrito nas Equações 2.9, 2.10 e 2.11. No modelo proposto, m é a média da imagem e d o desvio padrão, $B(x, y)$ é a função Beta, definida pela Equação 2.8, e os valores melhores valores encontrados através de regressão para as constantes são $\mu_m = 115.94$ e $\sigma_m = 27.99$, $\alpha_d = 4.4$ e $\beta_d = 10.1$.

$$B(x, y) = \int_0^1 t^{x-1} (1-t)^{y-1} dt \quad (2.8)$$

$$P_m(m) = \frac{1}{\sqrt{2\pi}\sigma_m} \exp\left[-\frac{m - \mu_m}{2\sigma_m^2}\right] \quad (2.9)$$

$$P_d(d) = \frac{(1-d)^{\beta_d-1} d^{\alpha_d-1}}{B(\alpha_d, \beta_d)} \quad (2.10)$$

$$N = \frac{1}{K} P_m P_d \quad (2.11)$$

2.2.1.6 *Measure of Enhancement*

A melhoria de imagens após um aprimoramento é em muitas vezes difícil de se medir. Em [65] é proposto uma métrica para fazer esse tipo de medição, o *Measure of Enhancement* (EME). Ele leva em consideração principalmente os vizinhos de cada pixel, pois afirma que a melhoria de um pixel depende mais fortemente dos pixels mais próximos. O EME considera uma imagem $x(n, m)$, separada em $k_1 \times k_2$ blocos, os cálculos são feitos como mostra a Equação 2.12, em que $I_{min;k,l}^w$ e $I_{max;k,l}^w$ são respectivamente, o menor e o maior valor da imagem x , dentro do bloco $w_{k,l}$.

$$EME_{k_1,k_2} = \frac{1}{k_1 k_2} \sum_{l=1}^{k_2} \sum_{k=1}^{k_1} 20 \log \left(\frac{I_{max;k,l}^w}{I_{min;k,l}^w} \right) \quad (2.12)$$

2.2.1.7 *Global Contrast Factor*

O contraste de uma imagem digital é definido pela razão entre o brilho do ponto com maior brilho e o ponto de menor brilho da imagem, mas ao em vez de focar nesses pontos, o *Global Contrast Factor* [66], foca em contrastes locais em diferentes níveis de resolução. O principal ponto do GCF é calcular o contraste local em diferentes frequências espaciais e usar esses valores para calcular o valor do GCF.

2.2.2 Local Binary Patterns

O *Local Binary Patterns* (LBP) [67] são descritores locais de textura baseados na suposição de que a informação de uma textura é dividida em dois aspectos complementares: padrão e intensidade.

Em [68] foi proposta uma nova forma de se calcular o LBP, utilizando uma vizinhança circular. Podemos definir ele da seguinte forma, considerando um ponto $g_c(x, y)$ em uma imagem em tons de cinza, P o número de pontos que se encontram na distância R de g_c , definimos os pontos $g_p(x_p, y_p)$, com $x_p = x + R * \cos(2\pi p/P)$ e $y_p = y - R * \sin(2\pi p/P)$. Quando o ponto calculado não coincide com o centro do *pixel* é feito uma interpolação bilinear. Então o valor do pixel é calculado como mostra a Equação 2.13, e por fim é feito o histograma da imagem, que descreve sua textura.

$$LBP_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p \quad (2.13)$$

2.2.3 Matriz de coocorrência

Uma matriz de coocorrência, é uma matriz que descreve quantas combinações diferentes de valores de intensidade dos *pixels* (níveis de cinza) ocorrem na imagem. Ela é utilizada principalmente para descrever a textura de uma imagem através de estatísticas que podemos extrair da matriz de coocorrência. As matrizes de coocorrência são utilizadas para classificação de imagens [69], porém seu custo computacional é alto e cresce a medida que cresce o número de níveis de cinza na imagem.

2.2.4 Melhoria de contraste em imagens digitais

Existem muitos métodos de melhoria de contraste em imagens digitais, a maioria se dá através de operações com o histograma, devido a sua facilidade de implementação e bons resultados [14].

2.2.4.1 Histograma

Em visão computacional, o histograma é um diagrama que representa a distribuição dos níveis das cores em uma imagem, usualmente os níveis de cinza, em que o eixo vertical representa a probabilidade daquele nível estar na imagem, e o eixo horizontal estão todos os níveis que podem ser assumidos pelos pixel naquela imagem. Na Figura 8 podemos observar alguns exemplos de histograma.

2.2.4.2 Equalização de Histograma

Equalização de histograma é uma técnica para ajustar as intensidades da imagem para melhorar o contraste [11].

Dada uma imagem T representada por uma matriz de *pixels* variando de 0 até $L-1$, sendo L o número de possibilidades dos valores de intensidade de cada *pixel*, normalmente 256. Sendo p o histograma normalizado da imagem ele é calculado com a Equação 2.14. Assim, a imagem G , com i e j sendo a linha e coluna do pixel, respectivamente, com o histograma equalizado seria definido com a equação 2.15.

$$p_n = \frac{\text{número de pixels com intensidade } n}{\text{número total de pixels}} \quad n = 0, 1, \dots, L-1 \quad (2.14)$$

$$G_{i,j} = \left\lfloor (L-1) \sum_{n=0}^{T_{i,j}} p_n \right\rfloor \quad (2.15)$$

Um exemplo de equalização de histograma pode ser visto na Figura 8.




Figura 8 – Histogramas com e sem equalização

As equalizações de histograma podem ser feitas de forma local ou global. Técnicas globais podem não ter um bom resultado em imagens que detalhes locais são importantes ou com grande variação de iluminação. Com equalização global, temos algumas técnicas, como o *Brightness Preserving Bi-Histogram Equalization* (BBHE) que separa o histograma no ponto médio e faz a equalização separada, que preserva o brilho e aumenta o contraste. Outro algoritmo de ajuste de histograma global, baseado no BBHE, é o *Minimum Mean Brightness Error Bi-Histogram Equalization*, que procura o ponto de separação com base na diferença de brilho entre a imagem de saída e entrada, e não mais a média.

2.2.4.3 Contrast Limited Adaptive Histogram Equalization

O CLAHE (*Contrast Limited Adaptive Histogram Equalization*) [6] é uma técnica de melhoramento de contraste local. Ele foi uma evolução do algoritmo *Adaptive*

Histogram Equalization (AHE). O AHE subdivide a imagem em regiões de tamanho parametrizado, podendo ser 8x8, 16x16, dependendo de cada problema. Para cada uma dessas regiões é executada uma equalização de histograma, e para evitar bordas marcadas é realizada uma interpolação bilinear. Porém, a desvantagem do AHE é o ruído gerado. Para resolver esse problema, o CLAHE limita o contraste, utilizando o parâmetro *Clip Limit*, em certas áreas do histograma. Essas áreas são caracterizadas por um pico no histograma, ou seja, quando muitos *pixels* estão na mesma região de nível de cinza. Quando isso acontece, e o valor daquele *bin* (valores no eixo das abscissas do histograma) ultrapassa o valor do parâmetro, o número de *pixels* acima desses valores são redistribuídos igualmente por todo o histograma. Na Figura 9 podemos observar a diferença entre o AHE e o CLAHE.

Cada parâmetro do CLAHE pode ser definido da seguinte forma:

- *Number of Tiles*: Número de regiões retangulares (*tiles*) em que a imagem original será dividida, pode ser especificado como um vetor de 2 elementos positivos. Cada elemento representa em quantas linhas e colunas a imagem original será dividida. Portanto, se o parâmetro é definido com $[M, N]$, serão encontradas $M \times N$ regiões para serem aplicadas a equalização de histograma.
- *Clip Limit*: É um fator de contraste que evita excesso de saturação em regiões homogêneas da imagem. Essas áreas, como já mencionado são as regiões com um pico no histograma. Sem esse parâmetro a técnica de equalização de histograma pode produzir resultados até piores que a imagem original.

Na Figura 10 podemos observar algumas diferenças que podem trazer a variação dos parâmetros *Clip Limit* e o *Number of Tiles*, com a imagem original (a) e sua distorcida (b). Visualmente podemos comparar como diferentes valores de CLAHE alteram os resultados (c,d,e). Com um CL baixo temos pouco aumento de contraste, e um CL muito alto a imagem acaba perdendo informações com um aspecto não desejado.




Figura 9 – Aplicação dos métodos em uma imagem real de uma ressonância magnética de um joelho [6]




Figura 10 – Variação de parâmetros do CLAHE. Imagem original (a), Imagem distorcida (b), CLAHE com parâmetros ruins: $CL = 0,01$ e $NT = [8, 8]$ (c), CLAHE com parâmetros ideais: $CL = 0,025$ e $NT = [4, 4]$ (d), CLAHE com parâmetros não adequados: $CL = 0,468$ e $NT = [16, 16]$ (e).

3 DESENVOLVIMENTO

Este capítulo explicará, primeiramente, a motivação da criação de uma nova base de dados e como nossa base foi construída. Na sequência, será apresentado como foi feita a rotulação das bases, e posteriormente, a extração dos descritores para o treinamento. Por fim, os algoritmos de AM utilizados são apresentados, juntamente com as métricas que serão utilizadas para a avaliação e a configuração geral do experimento.

3.1 Materiais e Métodos

Aprendizado supervisionado é uma tarefa de Aprendizado de Máquina (AM) cujo objetivo é induzir modelos a partir de dados previamente rotulados. Em outras palavras, usando uma base de treinamento composta de amostras de entradas com um alvo definido é possível construir um modelo para classificar uma nova amostra. Muitos algoritmos de AM são capazes de lidar com problemas de classificação e regressão [70].

Nosso objetivo era construir um modelo de regressão capaz de encontrar os parâmetros do CLAHE ajustados a uma imagem baseada em seus descritores. Para isso foi necessário construir uma base de treinamento adequada para indução do modelo.

Rotular as entradas do conjunto de treinamento no campo de visão computacional é um tarefa difícil, visto que muitas vezes essa tarefa é realizada por especialistas em aplicações bastante específicas, isto é, fica ainda mais difícil em situações em que se precisa rotular muitas amostras [71].

Para criar o conjunto de treinamento com os valores rotulados, automaticamente extraímos os descritores das imagens e estimamos valores ótimos de parâmetros do CLAHE. O processo precisava de imagens com contraste distorcido a partir de imagens de contraste ideais. Para cada imagem distorcida, iteramos as combinações de CL (de 0 a 1, com 0,001 em cada passo) e NT (de 2 até 32, com 2 em cada passo). O par de parâmetros que a imagem de saída era mais similar à imagem original era usado como rótulo.

Todas as bases de dados e os códigos fontes desenvolvidos estão disponíveis em ¹.

3.1.1 Construção das bases

Duas bases de imagens foram utilizadas nos nossos experimentos. A primeira, era composta de 246 imagens com contraste distorcido a partir de 54 imagens ideais. Essa base de imagens foi criada a partir da mescla de outras duas bases de imagens de IQA: CSIQ [72] e o TID2013 [73]. Nós utilizamos essas duas bases populares para avaliar nosso

¹ <http://www.uel.br/grupo-pesquisa/remid/?page_id=145>

método em diferentes cenários e distorções de qualidade. Além deste trabalho, CSIQ e o TID foram utilizados em vários trabalhos recentes com relação a contraste [14, 74, 61, 75].

Para aumentar a capacidade de generalização do nosso método, e também para validar cenários diferentes e mais difíceis, criamos outra base. Diferente da primeira base, nessa criamos distorções para cada imagem ideal das seguintes bases de IQA: [76, 77, 78, 79, 80, 81, 82, 83]. Para cada uma das 149 imagens ideais, criamos 42 distorções, assim a base é composta por 6258 imagens com constaste distorcido.

As 42 distorções foram construídas utilizando variações de contraste e intensidade. Cada imagem original considerada ideal pela literatura, teve seu contraste alterado pela compressão de seu histograma em seis níveis: -50%, 10%, 30%, 50%, 70% e 90%. Para a distorção de intensidade, para cada uma das distorções do histograma, o histograma foi deslocado em 10, 30 e 60 *bins* tanto para esquerda quanto para a direita, na Fig 11 pode-se visualizar o que ocorre nos histogramas em cada parte do processo. Na Figura 12, todas as variações de contraste de uma imagem original (sem variação de intensidade) podem ser vistas, e na Figura 13 é possível observar as variações de intensidades em uma imagem com constaste distorcido.

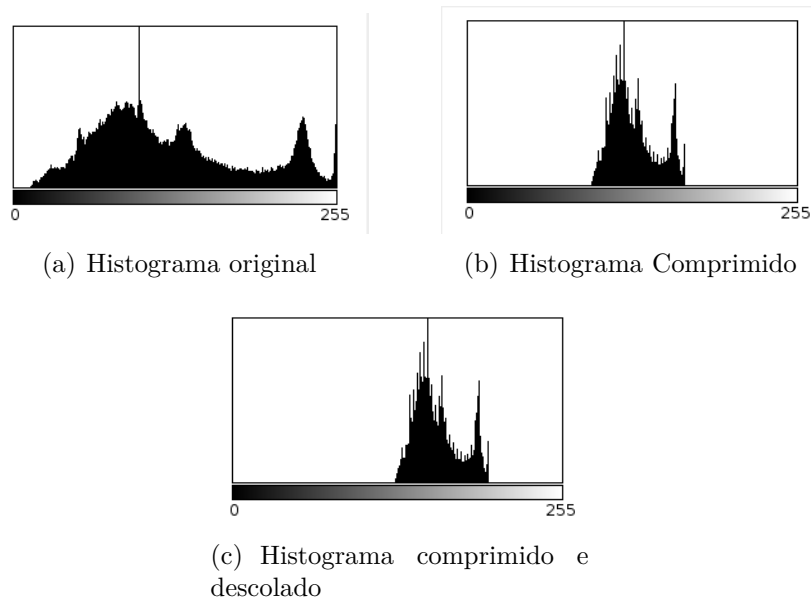


Figura 11 – Visualização do processo nos histogramas

O processo de compressão do histograma começa identificando os dois extremos das intensidades da imagem. Em outras palavras, pela extração da distância entre o *bin* mais a esquerda e o mais a direita. Então, a distância é reduzida ou aumentada para criar distorções de contraste. Utilizamos uma distribuição linear para obter os novos valores a esquerda, a direita e os pontos do meio do histograma comprimido. A biblioteca OpenCV² foi usada para implementar todas as distorções dessa base.

² <<http://www.opencv.org>>



Figura 12 – Distorções de contraste no Dataset 2. Imagem Original (a), Compressão de -50% (b), Compressão de 10% (c), Compressão de 30% (d), Compressão de 50% (e), Compressão de 70% (f), Compressão de 90% (g).

3.1.2 Rotulação do Dataset

O principal ponto do processo de rotulação é relacionar automaticamente os melhores valores dos parâmetros do CLAHE dada uma imagem com contraste distorcido com o objetivo de corrigi-la. Assim, aplicamos o CLAHE com todas as combinações possíveis nas imagens distorcidas. Em seguida, comparamos as saídas com a imagem original (antes das distorções de contraste), procurando pela imagem mais similar. Em outras palavras, tentamos todas as possibilidades de parâmetros para corrigir a imagem distorcida utilizando a original como parâmetro, para encontrar o melhor par. A Figura 10 mostra o resultado de diferentes escolhas dos parâmetros do CLAHE.

O processo é equivalente a análise de similaridade de imagens, que pode ser feito de três formas. A mais importante, nesse trabalho, foi a similaridade relacionada à qualidade de imagem, principalmente relacionada ao contraste. As técnicas de IQA que podem ser utilizadas com esse objetivo, como já explicado na seção 2.2.1 podem ser separadas em três grupos: *full-reference*, *reduced-reference* e *no-reference* [60, 61]. Quando se tem uma imagem para ser comparada com outra, as técnicas *full-references* são preferíveis [61]. Assim, usamos três medidas de avaliações *full-reference*: *Mean Squared Error* (MSE), *Peak*




Figura 13 – Deslocamento no histograma do **Dataset 2**. Imagem com contraste distorcido com 90% de compressão **(a)**, 10 bins para direita **(b)**, 30 para direita **(c)**, 60 para direita **(d)**, 10 bins para esquerda **(e)**, 30 para esquerda **(f)**, 60 bins para esquerda **(g)**.

Signal-to-Noise Ratio (PSNR) e o *Structural Similarity* (SSIM) [84, 60], outra métrica para avaliação que também foi utilizada foi o *Gray Level Entropy Difference* (GLED).

O MSE, PSNR, SSIM e GLED tem diferentes escalas e variação. Para criar um método confiável para indicar os parâmetros, ordenamos as métricas utilizando ranqueamento. O ranqueamento é realizado utilizando os valores desejados para cada métrica, isto é, os valores mais baixos de GLED e MSE e valores mais altos de PSNR e SSIM ficarão nas primeiras posições de suas métricas. Então, a amostra mais alta no *ranking* representa o par mais similar de imagens, portanto os parâmetros daquela amostra são considerados os parâmetros ótimos.

Esse processo é computacionalmente muito custoso, podendo se assemelhar ao [7] devido a variação de muitas combinações de parâmetros. Porém, esse processo é feito apenas uma vez para a rotulação da base de imagens, para a construção de um modelo preditivo. Após o modelo preditivo estar construído, para cada nova imagem será necessário apenas a extrair os descritores e a aplicação do modelo.

Na rotulação do **Dataset 1**, com 256 imagens, observamos que o processo levaria

muito tempo. Apenas para esse conjunto, o tempo necessário foi de cerca de 2 meses em um computador (Intel i5 e 6GB RAM) utilizando a biblioteca OpenCV. Como o **Dataset 2** é um conjunto muito maior de imagens, acabamos por utilizar um cluster composto de 18 computadores (Intel Xeon E5-2430v2 e 24 GB RAM), com Windows 7 e Matlab. O tempo necessário para rotulação do **Dataset 2** foi de 2 dias.

3.1.3 Descritores de Imagem

Agora que as amostras já estão com seus parâmetros ideais definidos para treinamento, cada imagem distorcida precisa ser descrita, para que assim os algoritmos de aprendizado de máquina possam ser usados para construir modelos.

Os descritores das imagens nos dão informações úteis para classificação e regressão automática [85]. Com esse propósito utilizamos um conjunto de 28 descritores para prever com precisão os valores de CL e NT. Esses descritores podem ser separados em quatro grupos principais: Espaciais, Histograma, Textura e Qualidade de Imagem.

Como descritores espaciais, foram selecionados dois momentos estatísticos (média e desvio padrão) e entropia dos níveis de cinza. Baseado nos momentos do histograma, extraímos o segundo (desvio padrão), o terceiro (*skewness*) e o quarto (*curtose*) como sugerido em [11, 86, 87, 88].

Utilizamos três descritores comuns de textura: *Local Binary Patterns* (LBP) [89], Matriz de Coocorrência da imagem em níveis de cinza [90] e características do domínio da frequência da FFT (*Fast Fourier Transform*) [85, 91]. Esses descritores de textura foram utilizados em uma grande variedade de aplicações de classificação de imagens [90].

Técnicas *full-reference* de IQA não podem ser utilizadas para compor o conjunto de descritores, visto que é necessário uma imagem ideal para encontrá-los. Em outras palavras, considerando uma imagem que precisa ser corrigida, em um problema real a imagem ideal é desconhecida. Assim, utilizamos três técnicas de IQA *no-reference* relacionados ao contraste para compor nosso vetor de descritores: *Statistical Naturalness Measure* (SNM) [64], *Measurement of Enhancement by Entropy* (EME) [65] e *Global Contrast Factor* (GCF) [66]. A lista completa de descritores utilizados nos experimentos é apresentada na Tabela 1.

Todos os descritores foram escalados para estar entre 0 e 1 antes da etapa de treinamento do aprendizado de máquina. Esse processo de padronização foi feito para evitar uma possível influência de diferentes variações durante a fase de indução do modelo.

3.1.4 Algoritmos utilizados

Nós avaliamos um total de cinco algoritmos de aprendizado de máquina para problemas de regressão, com propósito de determinar qual teria a melhor performance na

Tabela 1 – Lista de todos os descritores extraídos.

No.	Tipo	Descritor
01	Espacial	Valor médio dos pixels da imagem em tons de cinza
02	Espacial	Desvio padrão do valor dos pixels da imagem em tons de cinza
03	Espacial	Entropia da imagem em tons de cinza
04	Histograma	Desvio padrão do histograma da imagem em tons de cinza
05	Histograma	Curtose do histograma da imagem em tons de cinza
06	Histograma	<i>Skewness</i> do histograma da imagem em tons de cinza
07-16	Textura	Vetor de Local Binary Patterns (LBP)
17	Textura	Entropia da matriz de coocorrência de tons de cinza
18	Textura	Inercia da matriz de coocorrência de tons de cinza
19	Textura	Energia da matriz de coocorrência de tons de cinza
20	Textura	Correlação da matriz de coocorrência de tons de cinza
21	Textura	Homogeneidade da matriz de coocorrência de tons de cinza
22	Textura	Energia da FFT
23	Textura	Entropia da FFT
24	Textura	Inércia da FFT
25	Textura	Homogeneidade da FFT
26	Qualidade de Imagem	<i>Statistical Naturalness Measure</i> (SNM)
27	Qualidade de Imagem	<i>Measure of Enhancement</i> (EME)
28	Qualidade de Imagem	<i>Global Contrast Factor</i> (GCF)

predição automática dos parâmetros do CLAHE. A escolha foi feita baseada na aplicação em múltiplas tarefas de predição, pertencendo a grupos de algoritmos diferentes. Nesse sentido, *Classification and Regression Tree* (CART) [51], *Multi-layer Perceptron* (MLP) *Artificial Neural Network* [52], *Support Vector Machine* (SVM) [53], *Random Forest* (RF) [54], e *Extreme Gradient Boosting* (XGBoost) [55] foram escolhidos para os experimentos, pois são algoritmos tradicionalmente conhecidos por suas performances, e utilizados em inúmeras aplicações. Foram utilizados os parametros padrões do R para cada algoritmo. utilizando os pacotes `rpart` [92] (CART), `RSNNS package` [93] (MLP), `e1071` [94] (SVM), `randomForest` [95] (*Random Forest*) e `xgboost` [96] (XGBoost).

3.1.5 Medidas de Avaliação

Nós utilizamos o RMSE (*Root Mean Square Error*) e o coeficiente de determinação (R^2) como métricas de avaliação, para avaliar quanto os modelos de regressão puderam aproximar os valores desejados de NT e CL.

O RMSE é calculado com os parâmetros ideais determinados na construção do conjunto de treinamento e os valores preditos pelo modelo de regressão. A métrica é definida como a raiz da diferença quadrada entre os valores reais e os preditos para cada amostra, como definida pela equação 3.1, em que n é o número de amostras, y_i o valor correto, e \hat{y}_i o valor predito pelo modelo que está sendo avaliado. Ela mede quão próximos

Tabela 2 – Configuração dos Experimentos

Datasets	Dataset 1: 246 Imagens com contraste distorcido Dataset 2: 6258 Imagens com contraste distorcido
Técnicas de IQA <i>Full-Reference</i>	<i>Mean-Squared Error</i> (MSE) <i>Peak Signal-to-Noise Ratio</i> (PSNR) <i>Structural Similarity</i> (SSIM) <i>Gray Level Entropy</i> (GLED)
Descritores das Imagens	Espaciais (3 descritores) Histograma (3 descritores) Textura (19 descritores) Qualidade de Imagem (3 descritores)
Algoritmos de AM	<i>Classification and Regression Tree</i> (CART) <i>Multi-layer Perceptive</i> (MLP) <i>Support Vector Machine</i> (SVM) <i>Random Forest</i> (RF) <i>Extreme Gradient Boosting</i> (XGBoost)
Métricas de avaliação	<i>Root Mean Square Error</i> (RMSE) <i>R-squared</i> (R^2)

os valores esperados estão dos valores preditos pelo modelo induzido.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} . \quad (3.1)$$

O R^2 expressa a quantidade do total de variação associada com o uso de uma variável independente. O seu valor varia entre 0 e 1: quanto mais perto de um, maior é a proporção do total de variação na saída que é explicada introduzindo uma variável independente na regressão [97]. Assim, o R^2 mostra quão similar o comportamento dos valores preditos estão dos valores reais esperados. Todas essas informações estão presentes na Tabela 2.

4 RESULTADOS

Nesse capítulo, apresentamos os principais resultados dos experimentos. Primeiramente, mostramos os resultados relacionados a performance da predição de diferentes modelos dos algoritmos de AM. Em seguida, é apresentado uma comparação entre o LB-CLAHE e o [7]. Então, baseado no modelo de melhor performance, alguns resultados são discutidos no contexto de melhoria de imagem.

4.1 Performance Preditiva

Na Tabela 3 estão os resultados relacionados aos modelos induzidos pelos algoritmos de AM do **Dataset 1**, com os valores de RMSE e R^2 . Os resultados do **Dataset 2** estão na Tabela 4.

Para o **Dataset 1**, com a relação ao CL, os melhores resultados foram alcançados pelo XGBoost ($RMSE = 0,01; R^2 = 0,93$), seguido da RF ($RMSE = 0,03; R^2 = 0,86$). Ainda com relação ao **Dataset 1**, os melhores resultados da predição do NT foram alcançados pela SVM ($RMSE = 0,10; R^2 = 0,27$), e seguidos de perto pela RF ($RMSE = 0,11; R^2 = 0,25$). No **Dataset 2**, a RF alcançou os melhores resultados nos dois parâmetros, seguido pelo XGBoost. É possível observar que no geral, os métodos de *ensemble* obtiveram os melhores resultados. Os piores resultados foram da MLP, provavelmente pois um ajuste de parâmetros era necessário para alcançar melhores resultados.

Tabela 3 – Performance dos algoritmos de AM no **Dataset 1**

Algoritmos	<i>Clip Limit</i>		<i>Number of Tiles</i>	
	RMSE	R^2	RMSE	R^2
CART	0,04	0,70	0,12	0,15
MLP	0,03	0,85	0,11	0,24
SVM	0,04	0,85	0,10	0,27
RF	0,03	0,86	0,11	0,25
XGBoost	0,01	0,93	0,13	0,22

Tabela 4 – Performance dos algoritmos de AM no **Dataset 2**

Algoritmos	<i>Clip Limit</i>		<i>Number of Tiles</i>	
	RMSE	R^2	RMSE	R^2
CART	0,04	0,63	0,17	0,09
MLP	0,05	0,56	0,16	0,14
SVM	0,04	0,61	0,17	0,15
RF	0,03	0,76	0,14	0,37
XGBoost	0,03	0,76	0,14	0,35

No geral a performance de predição do NT não foi alta. Isso é justificado pois a qualidade da imagem depende principalmente do CL do que o NT [7]. Portanto a predição do NT pode não estar tão ligada aos descritores, o que dificulta a criação do modelo pelo algoritmo de aprendizado de máquina, já que valores diferentes de NT podem resultar em imagens adequadas.

4.2 Comparação visual

Aplicamos o LB-CLAHE no mesmo conjunto proposto em [7]. Apesar da comparação *Full-Reference* não ser possível, devido o trabalho não poder ser reproduzido, podemos observar na Figura 14, os dois métodos alcançaram resultados similares para todas imagens. Contudo, a proposta dos autores é computacionalmente muito custosa devido a executar o CLAHE com todos as combinações de parâmetros para uma única imagem. Nosso método extrai os descritores para prever os parâmetros e aplicar o CLAHE. Além disso, nosso método pode ser executado em milhares de imagens de diferentes contrastes e com variação de iluminação, enquanto o método anterior não foi testado extensivamente.

4.3 Importância dos descritores

Quando usamos a RF, é possível calcular a importância de cada variável no erro da predição. Em outras palavras, se substituímos os valores de um descritor particular por um valor aleatório, e isso resultar em uma melhora do erro, o descritor está relacionado ao problema de forma positiva, isto é, ajudando na descrição. Caso contrário, se o resultado é negativo, aquele descritor acaba por atrapalhar a descrição do problema e deve ser removido da modelagem. Esse procedimento deve ser feito para cada descritor para explicar seu impacto [54].

Utilizamos esse procedimento para investigar a contribuição de cada descritor utilizado para encontrar a melhor combinação de parâmetros do CLAHE. Na Figura 15, a importância de cada uma das variáveis está sendo apresentada. Podemos observar que não houve nenhuma que atingiu valores negativos, mostrando que nenhum descritor que atrapalhe a modelagem foi escolhido.

Para o *Clip Limit*, os momentos estatísticos do histograma da imagem em tons de cinza (descritores 4-6) foram importantes. É interessante notar que o descritor 4 foi importante somente no **Dataset 1**, enquanto os descritores 5 e 6 foram mais importantes no **Dataset 2**. Outros descritores como a energia da matriz de coocorrência (19), energia da FFT (22) e entropia da FFT (23) foram importantes em ambos os *datasets*. Apesar do pico do descritor de número 10 (LBP) no **Dataset 1**, os descritores do LBP obtiveram valores de importância médio. Diferente do esperado, os dois descritores baseados em




Figura 14 – Comparação visual entre o método proposto em [7] e LB-CLAHE. Imagem Escritório (a), Imagem área (b), Imagem do anúncio (c).

entropia (Entropia da imagem em tons de cinza (3), Entropia da matriz de coocorrência (17)), não obtiveram valores de importância altos.

Para os valores de NT, os resultados foram ligeiramente parecidos, com a energia da FFT (22) sendo o melhor descritor, considerando os dois *datasets*. Alguns outros picos foram apresentados pelo valor médio da imagem em tons de cinza (1) e o desvio padrão da imagem em tons de cinza (2), sugerindo que o valor do NT talvez tenha uma correlação com a imagem em tons de cinza.

No geral, nenhum descritor foi inútil. Para obter um processo de extração dos descritores mais rápido, remover os descritores menos importantes somente, talvez não seja proveitoso. Uma melhor opção é fazer uma seleção de descritores baseados em grupos, uma vez que a remoção de um grupo completo talvez tenha um impacto maior no tempo

Figura 15 – Importância de cada um dos descritores extraídos dos modelos da *Random Forest*, para ambos *datasets* e parâmetros.



de extração dos descritores.

4.4 Avaliação com IQA

Técnicas de IQA foram utilizadas para avaliar a similaridade entre as imagens ideais e as ajustadas utilizando os parâmetros sugeridos pelo LB-CLAHE. Então, para propósito de comparação, utilizamos duas técnicas para comparação: CLAHE com parâmetros fixos e equalização histograma global (EH Global). Fixamos os parâmetros com $CL=0,01$ e $NT = [8; 8]$, valores padrões do Matlab. Os resultados dessa comparação, para o **Dataset 1**, pode ser visto na Figura 16.

Os resultados para o **Dataset 2** foram similares. Apenas em um pequeno conjunto de imagens, o método proposto nesse trabalho não foi superior. Contudo, considerando valores médios, o LB-CLAHE teve um desempenho superior que as *baselines* utilizadas para as quatro técnicas de IQA utilizadas nas duas bases. Esses valores podem ser vistos na Tabela 5. No geral, não houve diferença muito grande entre as as quatro técnicas de IQA quanto a performance dos três métodos comparados.

A Figura 17 mostra as amostras obtidas pelo LB-CLAHE, com alta similaridade em relação a imagem original de acordo com as técnicas de IQA para diferentes cenários de contraste. Podemos observar quatro cenários diferentes: Na primeira linha, temos uma imagem com uma grande distorção de contraste, e nosso método foi capaz de sugerir os parâmetros que resultaram em uma imagem similar à imagem ideal. Na segunda, está sendo apresentado um cenário de uma distorção mediana no contraste, e o LB-CLAHE também apresentou ótimos resultados e diferente das técnicas comparadas não realçou o contraste além do ideal. Em seguida, um cenário de distorção leve é apresentado, e similar ao cenário anterior, o método proposto apenas ajustou o necessário. Por fim, temos um




Figura 16 – Performance do LB-CLAHE e as outras técnicas escolhidas utilizando IQA

cenário em que o contraste está acima do ideal, e portanto o comportamento esperado é não realçar ainda mais, e foi isso que o LB-CLAHE apresentou.

Como pode ser visto na Figura 16, houve um pequeno conjunto de imagens para as quais LB-CLAHE não foi superior de acordo com pelo menos três das quatro técnicas de IQA. Nos dois primeiros cenários (A e B), EH Global obteve o melhor resultado para a maioria das métricas, enquanto os dois últimos cenários (C e D), o CLAHE com parâmetros fixos foi a melhor opção, como mostrado na Figura 18. Os cenários apresentados na Figura 18, são similares à Figura 17. É importante mencionar que até nesses resultados o LB-CLAHE obteve um aspecto visual adequado. Além disso, para todas as imagens que o LB-CLAHE não foi o primeiro, ficou em segundo, com valores muito próximos da melhor opção em todas as métricas. Os valores de similaridade médios, obtidos entre a imagem ideal e as imagens distorcidas estão apresentadas na Tabela 5. Para todas as imagens avaliadas nos nosso experimentos, o LB-CLAHE obteve um aspecto visual adequado.

Figura 17 – Os melhores resultados do LB-CLAHE de acordo com as técnicas de IQA em diferentes cenários. Grande diminuição do contraste (**A**), diminuição mediana do contraste (**B**), diminuição leve do contraste (**C**), aumento de contraste (**D**). Imagem ideal (**1**), imagem distorcida (**2**), equalização de histograma global (**3**), CLAHE com valores fixos (**4**), valor proposto pelo LB-CLAHE (**5**)

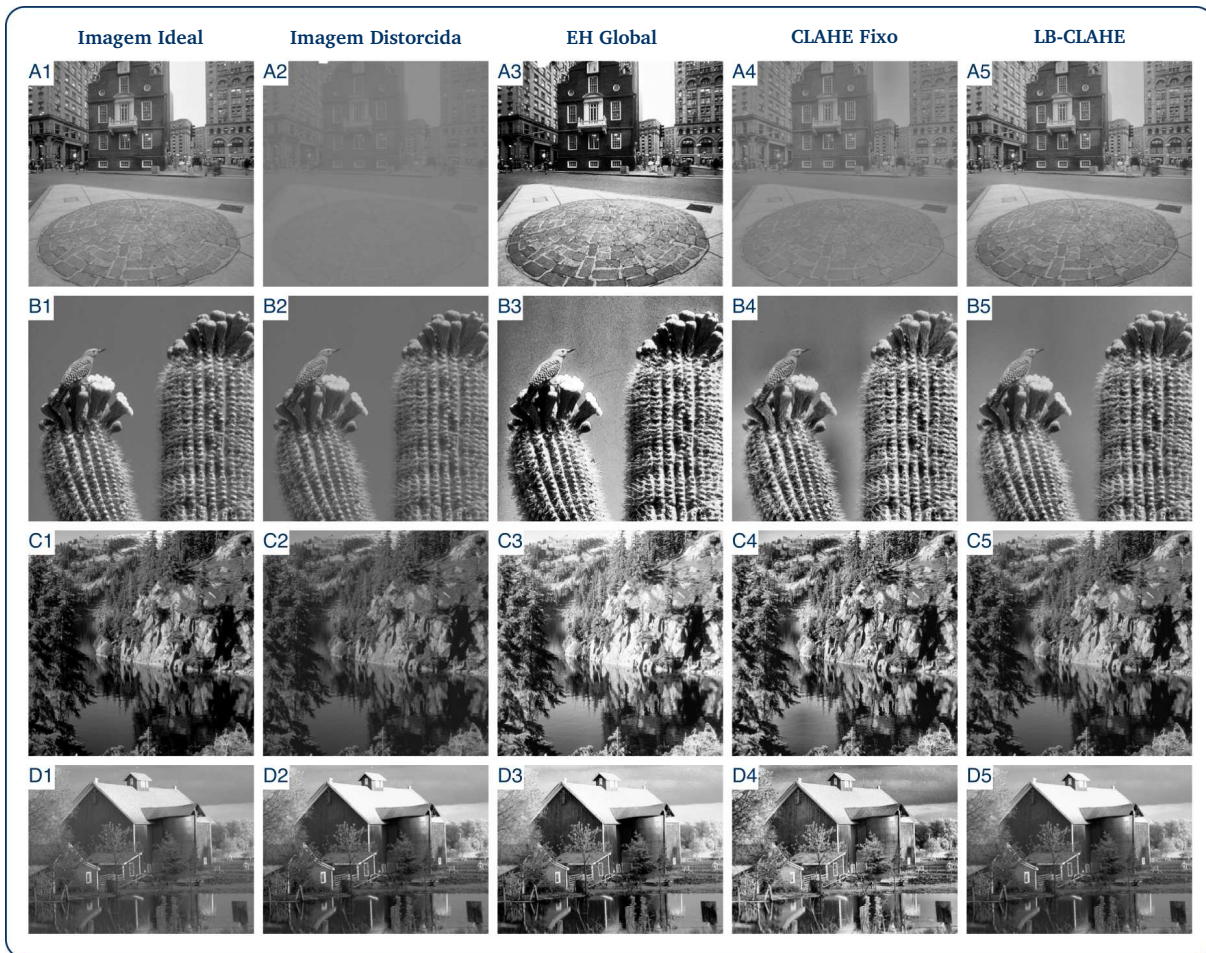



Tabela 5 – Valores médios de similaridade para o Dataset 1 e Dataset 2.

Dataset	Método	SSIM	PSNR	MSE	GLED
Dataset 1	EH Global	0,73	16,73	2046,12	1,76
	CLAHE Fixo	0,78	18,36	1075,52	0,50
	LB-CLAHE	0,90	23,39	396,26	0,22
Dataset 2	EH Global	0,75	16,51	2277,92	2,00
	CLAHE Fixo	0,77	16,48	1949,75	0,60
	LB-CLAHE	0,86	19,83	1181,10	0,17

Figura 18 – Os piores resultados do LB-CLAHE de acordo com as técnicas de IQA. Os melhores resultados da equalização de histograma global (A) e (B), melhores resultados do CLAHE com parâmetros fixos (C) e (D). Imagem ideal (1), imagem distorcida (2), equalização global do histograma (3), valores fixos do CLAHE 4, valor proposto pelo LB-CLAHE (5)



5 CONCLUSÃO

Muitas aplicações utilizam melhoria de contraste como tarefa de pré-processamento para as operações subsequentes obterem maior sucesso, mas para fazer essa melhoria ainda existem alguns problemas, pois alguns desse trabalhos utilizam algoritmos que precisam ser parametrizados, e uma seleção ruim pode afetar de forma negativa o resultado. Devido a esse problema de seleção de parâmetros, neste trabalho propomos um método baseado em aprendizado de máquina para fazer a seleção de parâmetros para o algoritmo de melhoria de contraste, denominado CLAHE.

O método proposto nesse trabalho, por utilizar aprendizado de máquina supervisionado, necessitou de instâncias previamente rotuladas, e para isso utilizamos métricas de IQA, e bases de dados conhecidas, além de sintetizar uma nova base utilizando distorções de contraste e intensidade, permitindo que nosso método fosse avaliado de uma forma mais abrangente, visto que cenários diferentes foram testados. Sobre essas duas bases aplicamos cinco algoritmos de aprendizado de máquina, e os comparamos utilizando métricas conhecidas de avaliação. Os algoritmos baseados em *ensemble* obtiveram os melhores resultados, a *Random Forest* e o *XGBoosting*, enquanto a MLP obteve os piores resultados.

Além da previsão dos parâmetros pudemos analisar o quanto cada descritor impacta a seleção dos parâmetros através da avaliação da importância dos descritores, e mostrou que nenhum descritor acaba tendo uma importância maior que os outros.

Em comparação as outras métricas escolhidas, (i) Equalização global de histograma e (ii) CLAHE com parâmetros fixos, o LB-CLAHE obteve resultados superiores utilizando métricas de IQA. O método proposto foi capaz de ajustar imagens de diferentes cenários e distorções de iluminação e contraste. Por fim, uma vez que o modelo foi criado, ele pode ser aplicado para sugerir parâmetros do CLAHE para uma nova imagem com tempo superior e uma performance preditiva maior que os métodos comparados.

REFERÊNCIAS

- [1] EVERYTHING you need to know about neural networks. <<http://opensourceforu.com/2017/03/neural-networks-in-detail/>>. Acessado: 02/11/2017.
- [2] GERONIMO, T. M. et al. Mlp and anfis applied to the prediction of hole diameters in the drilling process. In: SUZUKI, K. (Ed.). *Artificial Neural Networks - Architectures and Applications*. Rijeka: InTech, 2013. cap. 07. Disponível em: <<http://dx.doi.org/10.5772/51629>>.
- [3] ENSEMBLE Methods: Gradient Boosted Trees. <<https://www.add-for.com/2016/03/22/blog-post-gradient-boosted-trees/>>. Acessado: 08/11/2017.
- [4] INTRODUCTION to Support Vector Machine. <<https://www.dtrek.com/solution/view/20>>. Acessado: 27/09/2017.
- [5] ISIED, A.; TAMIMI, H. *Using Random Forest (RF) as a transfer learning classifier for detecting Error-Related Potential (ErrP) within the context of P300-Speller*. 2015.
- [6] ZUIDERVELD, K. Contrast limited adaptive histogram equalization. In: HECKBERT, P. S. (Ed.). *Graphics Gems IV*. San Diego, CA, USA: Academic Press Professional, Inc., 1994. p. 474–485.
- [7] MIN, B. S. et al. A novel method of determining parameters of clahe based on image entropy. *International Journal of Software Engineering & Its Applications*, v. 7, n. 5, p. 113–120, 2013.
- [8] ASMARE, M. H.; ASIRVADAM, V. S.; HANI, A. F. M. Image enhancement based on contourlet transform. *Signal, Image and Video Processing*, v. 9, n. 7, p. 1679–1690, 2015.
- [9] CHERIFI, D.; BEGHDADI, A.; BELBACHIR, A. H. Color contrast enhancement method using steerable pyramid transform. *Signal, Image and Video Processing*, v. 4, n. 2, p. 247–262, 2010.
- [10] HIARY, H. et al. Image contrast enhancement using geometric mean filter. *Signal, Image and Video Processing*, p. 1–8, 2016.
- [11] GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing*. Upper Saddle River, NJ, USA: Pearson/Prentice Hall, 2008.
- [12] HUANG, S. C.; CHENG, F. C.; CHIU, Y. S. Efficient contrast enhancement using adaptive gamma correction with weighting distribution. *IEEE Transactions on Image Processing*, v. 22, n. 3, p. 1032–1041, March 2013.
- [13] LAKSMI, T. V. H. et al. Novel image enhancement technique using clahe and wavelet transforms. *International Journal of Scientific Engineering and Technology*, v. 5, n. 11, p. 507–511, 2016.

- [14] SALEEM, A.; BEGHDADI, A.; BOASHASH, B. Image fusion-based contrast enhancement. *EURASIP Journal on Image and Video Processing*, v. 2012, n. 1, p. 1–17, 2012.
- [15] GUPTA, S.; KAUR, Y. Review of different local and global contrast enhancement techniques for a digital image. *International Journal of Computer Applications*, v. 100, n. 18, p. 18–23, 2014.
- [16] REZA, A. M. Realization of the contrast limited adaptive histogram equalization (clahe) for real-time image enhancement. *Journal of VLSI signal processing systems for signal, image and video technology*, v. 38, n. 1, p. 35–44, 2004.
- [17] MARUKATAT, S. Image enhancement using local intensity distribution equalization. *EURASIP Journal on Image and Video Processing*, v. 2015, n. 1, p. 1–18, 2015.
- [18] SUNDARAM, M. et al. Histogram modified local contrast enhancement for mammogram images. *Applied soft computing*, Elsevier, v. 11, n. 8, p. 5809–5816, 2011.
- [19] KIM, S. E.; JEON, J. J.; EOM, I. K. Image contrast enhancement using entropy scaling in wavelet domain. *Signal Processing*, v. 127, p. 1 – 11, 2016.
- [20] GÓMEZ, W. et al. Computerized lesion segmentation of breast ultrasound based on marker-controlled watershed transformation. *Medical Physics*, American Association of Physicists in Medicine, v. 37, n. 1, p. 82–95, 2010.
- [21] AKILA, K.; JAYASHREE, L.; VASUKI, A. Mammographic image enhancement using indirect contrast enhancement techniques – a comparative study. *Procedia Computer Science*, v. 47, p. 255 – 261, 2015. Graph Algorithms, High Performance Implementations and Its Applications (ICGHIA 2014).
- [22] FLORES, W. G.; PEREIRA, W. C. de A. A contrast enhancement method for improving the segmentation of breast lesions on ultrasonography. *Computers in Biology and Medicine*, v. 80, p. 14 – 23, 2017.
- [23] GEORGE, Y. M. et al. Automated cell nuclei segmentation for breast fine needle aspiration cytology. *Signal Processing*, v. 93, n. 10, p. 2804 – 2816, 2013. Signal and Image Processing Techniques for Detection of Breast Diseases.
- [24] TAREEF, A. et al. Automatic segmentation of overlapping cervical smear cells based on local distinctive features and guided shape deformation. *Neurocomputing*, v. 221, p. 94 – 107, 2017.
- [25] DATTA, N. S. et al. An effective approach: Image quality enhancement for microaneurysms detection of non-dilated retinal fundus image. *Procedia Technology*, v. 10, p. 731 – 737, 2013. First International Conference on Computational Intelligence: Modeling Techniques and Applications (CIMTA) 2013.
- [26] SINGH, N. P.; SRIVASTAVA, R. Retinal blood vessels segmentation by using gumbel probability distribution function based matched filter. *Computer Methods and Programs in Biomedicine*, v. 129, p. 40 – 50, 2016.

- [27] ASLANI, S.; SARNEL, H. A new supervised retinal vessel segmentation method based on robust hybrid features. *Biomedical Signal Processing and Control*, v. 30, p. 1 – 12, 2016.
- [28] PARVEEN, N. R. S.; SATHIK, M. M. Enhancement of bone fracture images by equalization methods. In: *2009 International Conference on Computer Technology and Development*. [S.l.: s.n.], 2009. v. 2, p. 391–394.
- [29] HITAM, M. S. et al. Mixture contrast limited adaptive histogram equalization for underwater image enhancement. In: *2013 International Conference on Computer Applications Technology (ICCAT)*. [S.l.: s.n.], 2013. p. 1–5.
- [30] ZHENG, L.; SHI, H.; SUN, S. Underwater image enhancement algorithm based on clahe and usm. In: *2016 IEEE International Conference on Information and Automation (ICIA)*. [S.l.: s.n.], 2016. p. 585–590.
- [31] QIAO, X. et al. Underwater image quality enhancement of sea cucumbers based on improved histogram equalization and wavelet transform. *Information Processing in Agriculture*, p. –, 2017.
- [32] MURILLO-BRACAMONTES, E. A. et al. Implementation of hough transform for fruit image segmentation. *Procedia Engineering*, v. 35, p. 230 – 239, 2012. International Meeting of Electrical Engineering Research 2012.
- [33] CHOI, D. et al. Detection of dropped citrus fruit on the ground and evaluation of decay stages in varying illumination conditions. *Computers and Electronics in Agriculture*, v. 127, p. 109 – 119, 2016.
- [34] JI, W. et al. Apple tree branch segmentation from images with small gray-level difference for agricultural harvesting robot. *Optik - International Journal for Light and Electron Optics*, v. 127, n. 23, p. 11173 – 11182, 2016.
- [35] UNZUETA, L. et al. Adaptive multicue background subtraction for robust vehicle counting and classification. *IEEE Transactions on Intelligent Transportation Systems*, v. 13, n. 2, p. 527–540, June 2012.
- [36] GUDIGAR, A. et al. Local texture patterns for traffic sign recognition using higher order spectra. *Pattern Recognition Letters*, v. 94, p. 202 – 210, 2017.
- [37] WANG, X. et al. Research on pedestrian detection method with motion and shape features. *Journal of Computational and Theoretical Nanoscience*, American Scientific Publishers, v. 13, n. 9, p. 5788–5793, 2016.
- [38] HIARY, H. et al. Image contrast enhancement using geometric mean filter. *Signal, Image and Video Processing*, v. 11, n. 5, p. 833–840, 2017.
- [39] SEPASIAN, M.; BALACHANDRAN, W.; MARES, C. Image enhancement for fingerprint minutiae-based algorithms using clahe, standard deviation analysis and sliding neighborhood. In: *Proceedings of the World congress on Engineering and Computer Science*. [S.l.: s.n.], 2008. p. 22–24.
- [40] LOZA, A. et al. Automatic contrast enhancement of low-light images based on local statistics of wavelet coefficients. *Digital Signal Processing*, v. 23, n. 6, p. 1856 – 1866, 2013.

- [41] SASI, N. M.; JAYASREE, V. Contrast limited adaptive histogram equalization for qualitative enhancement of myocardial perfusion images. *Engineering, Scientific Research Publishing*, v. 5, p. 326, 2013.
- [42] MORÉ, L. G. et al. Parameter tuning of clahe based on multi-objective optimization to achieve different contrast levels in medical images. In: *2015 IEEE International Conference on Image Processing (ICIP)*. [S.l.: s.n.], 2015. p. 4644–4648.
- [43] KO, B. C.; GIM, J. W.; NAM, J. Y. Cell image classification based on ensemble features and random forest. *Electronics Letters*, v. 47, n. 11, p. 638–639, May 2011.
- [44] SHANMUGAMANI, R.; SADIQUE, M.; RAMAMOORTHY, B. Detection and classification of surface defects of gun barrels using computer vision and machine learning. *Measurement*, v. 60, p. 222 – 230, 2015. ISSN 0263-2241.
- [45] LI, P. et al. A cloud image detection method based on svm vector machine. *Neurocomputing*, v. 169, p. 34 – 42, 2015. Learning for Visual Semantic Understanding in Big Data ESANN 2014 Industrial Data Processing and Analysis.
- [46] QUINTANA, M.; TORRES, J.; MENÉNDEZ, J. M. A simplified computer vision system for road surface inspection and maintenance. *IEEE Transactions on Intelligent Transportation Systems*, v. 17, n. 3, p. 608–619, March 2016.
- [47] SHARMA, S. U.; SHAH, D. J. A practical animal detection and collision avoidance system using computer vision technique. *IEEE Access*, v. 5, p. 347–358, 2017.
- [48] BISHOP, C. M. *Pattern recognition and machine learning*. [S.l.]: springer, 2006.
- [49] KOTSIANTIS, S. B.; ZAHARAKIS, I. D.; PINTELAS, P. E. Machine learning: a review of classification and combining techniques. *Artificial Intelligence Review*, Kluwer Academic Publishers, v. 26, n. 3, p. 159–190, 2006.
- [50] FENG, W. et al. A support vector machine based naive bayes algorithm for spam filtering. In: IEEE. *Performance Computing and Communications Conference (IPCCC), 2016 IEEE 35th International*. [S.l.], 2016. p. 1–8.
- [51] BREIMAN, L. et al. *Classification and regression trees*. New York: CRC press, 1984.
- [52] HAYKIN, S. *Neural network: A compressive foundation*. [S.l.]: Upper Saddle River, New Jersey: Prentice Hall, 1999.
- [53] VAPNIK, V. *The Nature of Statistical Learning Theory*. [S.l.]: Springer-Verlag, 1995.
- [54] BREIMAN, L. Random forests. *Mach. Learn.*, v. 45, n. 1, p. 5–32, out. 2001. ISSN 0885-6125.
- [55] CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: ACM. *Proceedings of the 22Nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.], 2016. p. 785–794.
- [56] FISHER, R. A. The use of multiple measurements in taxonomic problems. *Annals of human genetics*, Wiley Online Library, v. 7, n. 2, p. 179–188, 1936.

- [57] BRAUN, A. C.; WEIDNER, U.; HINZ, S. Classification in high-dimensional feature spaces—assessment using svm, ivm and rvm with focus on simulated enmap data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, IEEE, v. 5, n. 2, p. 436–443, 2012.
- [58] ZHANG, C.; GUO, J.; LU, J. Research on classification method of high-dimensional class-imbalanced data sets based on svm. In: IEEE. *Data Science in Cyberspace (DSC), 2017 IEEE Second International Conference on*. [S.l.], 2017. p. 60–67.
- [59] BREIMAN, L. Random forests. *Machine learning*, Springer, v. 45, n. 1, p. 5–32, 2001.
- [60] V., H. Y.; PATIL, H. Y. Article: A survey on image quality assessment techniques, challenges and databases. *IJCA Proceedings on National Conference on Advances in Computing*, NCAC 2015, n. 7, p. 34–38, December 2015. Full text available.
- [61] SHOKROLLAHI, A.; MAHMOUDI-AZNAVEH, A.; MAYBODI, B. M.-N. Image quality assessment for contrast enhancement evaluation. *AEU - International Journal of Electronics and Communications*, v. 77, p. 61–66, 2017.
- [62] WANG, Z. et al. Image quality assessment: from error visibility to structural similarity. *IEEE Transactions on Image Processing*, v. 13, n. 4, p. 600–612, April 2004. ISSN 1057-7149.
- [63] GU, K. et al. The analysis of image contrast: From quality assessment to automatic enhancement. *IEEE Transactions on Cybernetics*, v. 46, n. 1, p. 284–297, Jan 2016.
- [64] YEGANEH, H.; WANG, Z. Objective quality assessment of tone-mapped images. *IEEE Transactions on Image Processing*, v. 22, n. 2, p. 657–667, 2013.
- [65] AGAIAN, S. S.; PANETTA, K.; GRIGORYAN, A. M. Transform-based image enhancement algorithms with performance measure. *IEEE Transactions on Image Processing*, v. 10, n. 3, p. 367–382, 2001.
- [66] MATKOVIĆ, K. et al. Global contrast factor - a new approach to image contrast. In: *Proceedings of the First Eurographics Conference on Computational Aesthetics in Graphics, Visualization and Imaging*. [S.l.: s.n.], 2005. p. 159–167.
- [67] HE, D.-C.; WANG, L. Texture unit, texture spectrum, and texture analysis. *IEEE transactions on Geoscience and Remote Sensing*, IEEE, v. 28, n. 4, p. 509–512, 1990.
- [68] OJALA, T.; PIETIKAINEN, M.; MAENPAA, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 24, n. 7, p. 971–987, Jul 2002. ISSN 0162-8828.
- [69] NASCIMENTO, J. P. R.; MADEIRA, H. M. F.; PEDRINI, H. Classificação de imagens utilizando descritores estatísticos de textura. *XI Simpósio Brasileiro de Sensoriamento Remoto*, 2003.
- [70] MITCHELL, T. M. *Machine Learning*. New York: McGraw Hill, 1997.
- [71] YAO, Y. et al. A new web-supervised method for image dataset constructions. *Neurocomputing*, Elsevier, v. 236, p. 23–31, 2017.

- [72] LARSON, E. C.; CHANDLER, D. M. Most apparent distortion: full-reference image quality assessment and the role of strategy. *Journal of Electronic Imaging*, International Society for Optics and Photonics, v. 19, n. 1, p. 011006–011006, 2010.
- [73] PONOMARENKO, N. et al. Color image database tid2013: Peculiarities and preliminary results. In: IEEE. *Visual Information Processing (EUVIP), 2013 4th European Workshop on*. [S.l.], 2013. p. 106–111.
- [74] SIMONE, G. et al. Multi-level contrast filtering in image difference metrics. *EURASIP Journal on Image and Video Processing*, v. 2013, n. 1, p. 39, Jul 2013.
- [75] SALEEM, A.; BEGHDADI, A.; BOASHASH, B. A distortion-free contrast enhancement technique based on a perceptual fusion scheme. *Neurocomputing*, v. 226, p. 161 – 167, 2017. ISSN 0925-2312.
- [76] ZARIĆ, A. et al. Vcl@ fer image quality assessment database. *AUTOMATIKA: časopis za automatiku, mjerenje, elektroniku, računarstvo i komunikacije*, KoREMA-Hrvatsko društvo za komunikacije, računarstvo, elektroniku, mjerenja i automatiku, v. 53, n. 4, p. 344–354, 2012.
- [77] LIN, J. Y. et al. Statistical study on perceived jpeg image quality via mcl-jci dataset construction and analysis. *Electronic Imaging*, Society for Imaging Science and Technology, v. 2016, n. 13, p. 1–9, 2016.
- [78] HU, S.; WANG, H.; KUO, C.-C. J. A gmm-based stair quality model for human perceived jpeg images. In: IEEE. *Acoustics, Speech and Signal Processing (ICASSP), 2016 IEEE International Conference on*. [S.l.], 2016. p. 1070–1074.
- [79] LIN, J. Y. et al. Experimental design and analysis of jnd test on coded image/video. In: INTERNATIONAL SOCIETY FOR OPTICS AND PHOTONICS. *SPIE Optical Engineering+ Applications*. [S.l.], 2015. p. 95990Z–95990Z.
- [80] CALLET, P. L.; AUTRUSSEAU, F. *Subjective quality assessment IRCCyN/IVC database*. 2005. [Http://www.irccyn.ec-nantes.fr/ivcdb/](http://www.irccyn.ec-nantes.fr/ivcdb/).
- [81] SHEIKH, H. et al. *LIVE image quality assessment database release 2 (2005)*. 2005.
- [82] SHEIKH, H. R.; SABIR, M. F.; BOVIK, A. C. A statistical evaluation of recent full reference image quality assessment algorithms. *IEEE Transactions on image processing*, IEEE, v. 15, n. 11, p. 3440–3451, 2006.
- [83] WANG, Z. et al. Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, IEEE, v. 13, n. 4, p. 600–612, 2004.
- [84] THAKUR, N.; DEVI, S. A new method for color image quality assessment. *International Journal of Computer Applications*, v. 15, n. 2, p. 10–17, 2011.
- [85] NIXON, M. S.; AGUADO, A. S. *Feature Extraction & Image Processing for Computer Vision*. Oxford: Academic Press, 2012.
- [86] BALAJI, G. N.; SUBASHINI, T. S.; CHIDAMBARAM, N. Automatic classification of cardiac views in echocardiogram using histogram and statistical features. *Procedia Computer Science*, v. 46, n. 0, p. 1569–1576, 2015.

- [87] LI, D. et al. Pornographic images recognition based on spatial pyramid partition and multi-instance ensemble learning. *Knowledge-Based Systems*, v. 84, p. 214–223, 2015.
- [88] CAMPOS, G. F. C. et al. Supervised approach for indication of contrast enhancement in application of image segmentation. In: *MMEDIA 2016, The Eighth International Conferences on Advances in Multimedia*. [S.l.: s.n.], 2016. p. 12–18.
- [89] OJALA, T.; PIETIKÄINEN, M.; MÄENPÄÄ, T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 24, n. 7, p. 971–987, Jul 2002.
- [90] HARALICK, R. M.; SHANMUGAM, K.; DINSTEN, I. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3, n. 6, p. 610–621, Nov 1973.
- [91] SHEN, H.; CHEN, P.; CHANG, L. Automated steel bridge coating rust defect recognition method based on color and texture feature. *Automation in Construction*, v. 31, n. 0, p. 338–356, 2013.
- [92] THERNEAU, T.; ATKINSON, B.; RIPLEY, B. *rpart: Recursive Partitioning and Regression Trees*. [S.l.], 2017. R package version 4.1-11. Disponível em: <<https://CRAN.R-project.org/package=rpart>>.
- [93] BERGMEIR, C.; BENÍTEZ, J. M. Neural networks in R using the stuttgart neural network simulator: RSNNS. *Journal of Statistical Software*, v. 46, n. 7, p. 1–26, 2012. Disponível em: <<http://www.jstatsoft.org/v46/i07/>>.
- [94] MEYER, D. et al. *e1071: Misc Functions of the Department of Statistics, Probability Theory Group (Formerly: E1071), TU Wien*. [S.l.], 2017. R package version 1.6-8. Disponível em: <<https://CRAN.R-project.org/package=e1071>>.
- [95] LIAW, A.; WIENER, M. Classification and regression by randomforest. *R News*, v. 2, n. 3, p. 18–22, 2002. Disponível em: <<http://CRAN.R-project.org/doc/Rnews/>>.
- [96] CHEN, T. et al. *xgboost: Extreme Gradient Boosting*. [S.l.], 2017. R package version 0.6-4. Disponível em: <<https://CRAN.R-project.org/package=xgboost>>.
- [97] CORNELL, J. A.; BERGER, R. D. Factors that influence the value of the coefficient of determination in simple linear and nonlinear regression models. *Phytopathology*, v. 77, n. 1, p. 63–70, 1987.